

Informe técnico: Base de conocimiento vectorial

CODEFEST AD ASTRA 2026 · Etapa 1

Equipo: Git Init (Juan Pablo Díaz, Samuel Antonio Castro, Nicolas Arce y Wolfgang Felipe Guzman)

Fecha: 13 de agosto de 2026

1. Arquitectura general

El sistema construye una base de conocimiento vectorial procesando el corpus multilingüe de ADL (~1.848 archivos, 3 fenómenos). Para las 50 consultas, el sistema devuelve los 3 documentos y los 10 fragmentos más relevantes por cada una, utilizando únicamente métodos de recuperación y sin recurrir a modelos generativos (§8.3).

Procesamos todos los formatos del corpus: PDF (usando PyMuPDF, con soporte de OCR por página para documentos escaneados), HTML (BeautifulSoup), JSON (con un parser propio para evitar duplicar el cuerpo), CSV/XLSX (mediante pandas, con tolerancia a fallos), TXT/MD, imágenes (Tesseract configurado para spa+eng+por) y PBF (mapbox-vector-tile).

En lugar de descartar los formatos más ruidosos como OCR o mapas, les aplicamos filtros de calidad. El proceso de limpieza incluye: normalización de Unicode (NFC), unificación de saltos de línea (U+2028/U+2029 → \n), unión de palabras cortadas por guiones, eliminación de encabezados/pies de página repetitivos y detección de idioma por documento.

2. Preprocesamiento y extracción de texto

El corpus provisto reúne 1.839 archivos en siete formatos distintos. Se procesaron todos ellos: PDF mediante PyMuPDF, HTML con BeautifulSoup eliminando marcado y scripts, JSON con un intérprete propio de campos, CSV y XLSX con pandas convirtiendo cada fila a texto `columna: valor`, imágenes por OCR y mapas vectoriales PBF decodificando sus atributos. La decisión de no descartar ningún formato se tomó frente a la alternativa de ignorar los más ruidosos; se optó por incorporarlos con filtros de calidad específicos en lugar de perder su contenido.

Tres decisiones de extracción merecen mención porque corrigen pérdidas de datos que de otro modo habrían pasado inadvertidas:

OCR de respaldo para PDFs escaneados. Cuando una página de PDF no contiene capa de texto, se renderiza a imagen y se procesa con Tesseract. La necesidad no era teórica: 47 de los 62 PDFs de las Alertas Tempranas de la Defensoría del Pueblo son escaneos, y sin este respaldo se descartaban íntegros. Se trata de 367 MB de informes sobre grupos armados y control territorial, la fuente más pertinente para las consultas del tercer fenómeno. Incorporarlos elevó esa carpeta de 794 a 1.768 fragmentos y recuperó 45 documentos. El respaldo actúa página por página y únicamente cuando no

hay texto extraíble, de modo que los PDFs con capa de texto no incurren en ningún costo adicional.

Selección de una única fuente de cuerpo en JSON. Los artículos en JSON incluyen simultáneamente los campos `body_text` y `body_paragraphs` con el mismo contenido. Concatenar ambos habría duplicado el cuerpo de cada documento e inflado el índice con texto repetido, de modo que se selecciona explícitamente una sola fuente.

Tolerancia a CSV malformados. Varios CSV del corpus emplean separadores distintos de la coma o contienen filas con más campos que la cabecera, lo que hacía fallar el parseo y perder el archivo completo. Ante un fallo se reintenta con detección automática de separador y descarte de las filas irrecuperables. El resultado es que los 26 CSV del corpus se extraen correctamente.

En la limpieza posterior se normaliza a Unicode NFC, se eliminan caracteres de control, se reunifican las palabras partidas por guión al final de línea —muy frecuentes en PDFs maquetados a columnas— y se suprimen encabezados y pies recurrentes, identificados como líneas cortas que se repiten cuatro o más veces en un mismo documento. Se unifican además los separadores de línea Unicode (U+2028, U+2029, U+0085) a salto de línea convencional, porque de lo contrario rompen la lectura posterior del almacén de metadata en formato JSON Lines.

3. Estrategia de chunking (§3)

Decisión: fragmentación híbrida, con cortes en frontera de oración, empaque goloso hasta 450 tokens y solapamiento de una oración entre fragmentos consecutivos.

El procedimiento divide el texto en oraciones completas, acumula oraciones consecutivas mientras quepan en el límite de tokens, cierra el fragmento al alcanzarlo y comienza el siguiente conservando la última oración del anterior.

Se descartaron las dos estrategias puras por motivos opuestos. La fragmentación por oración individual produce unidades demasiado breves, con contexto insuficiente para que el encoder las sitúe semánticamente, y multiplica innecesariamente el tamaño del índice. La fragmentación por tamaño fijo en tokens, en cambio, corta oraciones por la mitad: además de degradar la calidad del embedding, incumple el requisito de completitud lingüística, que exige que los fragmentos entregados sean unidades de texto completas y legibles. El enfoque híbrido conserva la propiedad relevante de cada una: unidades semánticas íntegras y de extensión suficiente.

El límite de 450 tokens deja margen deliberado bajo los 512 que admite el encoder. El solapamiento de una oración asegura que una idea que cruza la frontera entre dos

fragmentos quede representada en ambos. Se descartan los fragmentos de menos de 20 tokens por carecer de contenido aprovechable.

Tope de fragmentos por documento. Se limita a 2.000 la cantidad de fragmentos que un solo documento puede aportar al índice. El corpus incluye volcados bibliográficos en CSV de hasta 35 MB; uno solo de ellos generaba alrededor de 36.000 fragmentos y el conjunto superaba los 110.000, más de la mitad del índice completo procedente de cinco archivos. El tope responde a tres razones: un documento con decenas de miles de fragmentos dispone de otras tantas oportunidades de producir una coincidencia alta por azar y compite con ventaja injusta en la agregación a nivel documento; monopoliza el conjunto de candidatos y desplaza a documentos distintos; y duplicaba con creces el tiempo de indexación para incorporar listados de metadatos bibliográficos. El límite es general, no una excepción dirigida a archivos concretos, y está fijado donde ningún documento de prosa lo alcanza —el PDF más extenso del corpus produce alrededor de 500 fragmentos—, de modo que en la práctica solo afecta a estructuras tabulares. Los documentos recortados permanecen en el índice y siguen siendo recuperables.

Caso límite documentado. Una oración que por sí sola excede el límite no puede dividirse sin cortarla, por lo que se emite como fragmento propio. Si supera los 512 tokens del encoder, este la trunca al codificar y el vector no representa su parte final, aunque el texto íntegro se conserva en la metadata y el fragmento entregado está completo. Afecta a 6.568 fragmentos (8,3% del índice), pero se concentra casi por entero en formatos tabulares: de los 47.293 fragmentos procedentes de PDF, exactamente uno resultó truncado. En conjunto queda sin representar el 2,8% de los tokens del corpus.

4. Selección del encoder

Decisión: ``intfloat/multilingual-e5-large``.

Se evaluó contra los seis criterios establecidos por la especificación:

Criterio	Cumplimiento
Soporte multilingüe	Nativo en español, inglés y portugués; base XLM-RoBERTa entrenada sobre 100 idiomas
Dimensionalidad	1.024
Longitud máxima de entrada	512 tokens, magnitud que condiciona directamente la estrategia de chunking
Rendimiento en benchmarks	Posiciones destacadas en las tablas de recuperación de MTEB y BEIR
Licencia	MIT
Eficiencia computacional	2,2 GB de parámetros; inviable en CPU para indexación, resuelto mediante GPU

Se trata de un modelo encoder, conforme a la prohibición de emplear arquitecturas decoder. La familia e5 fue entrenada con prefijos explícitos y los requiere en inferencia (`query`: para consultas, `passage`: para fragmentos); omitirlos degrada la calidad de forma silenciosa, por lo que se aplican de manera sistemática. Los embeddings se producen normalizados, lo que permite emplear producto interno como similitud coseno.

Decisión de no incorporar un segundo encoder. La especificación permite construir la base con varios encoders y describe estrategias para fusionar sus rankings. Se evaluó la opción y se descartó por tres razones: duplica el costo de indexación, que constituía el cuello de botella real del proyecto; duplica el tamaño de la entrega; y, de manera decisiva, no existía forma de verificar que mejorara el resultado, dado que sin juicios de relevancia no puede medirse si la fusión eleva o reduce las métricas. La fusión por rangos pondera por igual a ambos encoders con independencia de su calidad, de modo que incorporar uno inferior arrastra el ranking hacia abajo. Se optó por no adoptar a ciegas una técnica cuyo efecto no podía medirse. La arquitectura del proyecto la soporta si en el futuro se dispone de datos de validación.

5. Base de datos vectorial (§5)

Decisión: `IndexFlatIP` de FAISS sobre vectores normalizados.

Con los vectores normalizados, el producto interno equivale matemáticamente a la similitud coseno, de modo que no se requiere un índice específico para esta métrica. `IndexFlatIP` realiza búsqueda exacta comparando la consulta contra la totalidad de los vectores, con recuperación completa garantizada.

Se consideraron los índices aproximados que ofrece FAISS. Tanto la cuantificación vectorial invertida como los grafos de proximidad intercambian exactitud por velocidad, y esa compensación solo resulta ventajosa a escala de millones de vectores. Con los 79.141 fragmentos del corpus, la búsqueda exacta responde en milisegundos: aceptar una pérdida de recuperación no habría aportado ningún beneficio observable.

Invariante de alineación. El identificador interno que FAISS asigna a cada vector corresponde a su posición de inserción, de modo que la línea i del almacén de metadata debe describir exactamente el fragmento cuyo vector ocupa la posición i . Romper ese orden inutiliza el índice completo. Se garantiza manteniendo una única lista de fragmentos que sirve simultáneamente para codificar y para escribir la metadata, y se verifica automáticamente en tres puntos del flujo: al construir el índice, al fusionar índices parciales y al empaquetar la entrega.

6. Módulo de recuperación (§8, §9)

6.1 Conjunto de candidatos

Decisión: recuperar 200 fragmentos candidatos por consulta.

El valor inicial de 50 se elevó a partir de una observación empírica: existían consultas cuyos 50 fragmentos candidatos procedían de únicamente dos documentos distintos, de modo que el sistema no podía devolver tres documentos aunque el corpus los contuviera, con pérdida garantizada de recuperación a nivel documento. La causa es la distribución del corpus, donde ciertos documentos generan cientos de fragmentos y copan el conjunto de candidatos por sí solos.

6.2 Agregación a nivel documento

El índice conoce únicamente fragmentos, de modo que los tres documentos deben derivarse agrupando los candidatos por documento de origen y asignando una puntuación agregada a cada uno. Se implementaron y compararon cuatro estrategias: máximo, suma, media y suma de los m mejores fragmentos.

Conviene señalar una propiedad que simplifica el análisis: la suma de los m mejores no constituye una cuarta estrategia independiente, sino el continuo entre las otras dos. Con m igual a uno equivale exactamente al máximo, y con m mayor o igual al número de fragmentos del documento equivale exactamente a la suma. El parámetro regula cuánta acumulación de evidencia se permite. La equivalencia se verificó empíricamente sobre las 50 consultas y se empleó como control de validez del experimento.

Decisión: suma de los tres mejores fragmentos por documento.

Se partió del máximo como estrategia de referencia y se modificó a partir de la evidencia recogida sobre el corpus completo:

Estrategia	Documentos del fenómeno esperado	Consultas con al menos un documento ajeno
Máximo	108/150 (72%)	18/50
Media	96/150 (64%)	22/50
Suma	137/150 (91%)	8/50
Suma de los 3 mejores	138/150 (92%)	7/50
Suma de los 5 mejores	140/150 (93%)	6/50

La mejora es sustancial y estable: las consultas que incorporan algún documento ajeno al fenómeno se reducen de 18 a 7, y el resultado se mantiene para valores de m entre 2 y 10, de modo que no depende de acertar con el parámetro.

Más relevante que la cifra es el mecanismo del fallo identificado. Bajo la estrategia de máximo basta un único fragmento afortunado para que un documento puntúe alto, de modo que los documentos que aportan un solo fragmento compiten en igualdad de condiciones con informes de centenares. El efecto observado era extremo: un mismo artículo aparecía en catorce de las dieciséis consultas del primer fenómeno. Eso no constituye recuperación sino un artefacto de concentración: un documento genéricamente próximo a cualquier pregunta del área, incapaz de discriminar entre ellas. Al exigir tres fragmentos buenos, ese documento deja de dominar y entran en su

lugar las fuentes especializadas: las posiciones ocupadas por publicaciones propias del dominio de inteligencia artificial aplicada a defensa pasaron de 2 a 11 sobre 48.

La estrategia de media quedó descartada con datos: es la peor de las cuatro y empeora al ampliar el conjunto de candidatos, dado que cada documento recibe más fragmentos de similitud baja que reducen su promedio.

Es importante precisar el alcance del cambio: afecta exclusivamente a la métrica de documentos. Los diez fragmentos se seleccionan por similitud directa sin pasar por la agregación, de modo que la métrica de fragmentos es idéntica bajo cualquiera de las cuatro estrategias.

6.3 Selección y re-ordenamiento de fragmentos

Los fragmentos entregados se obtienen recorriendo los candidatos por similitud descendente y dividiendo cada uno en sub-fragmentos de 250 palabras como máximo sin cortar oraciones. Dado que la mediana de un fragmento del índice es de 253 palabras, la división se aplica al 51% de ellos. Como consecuencia, varios fragmentos de una misma respuesta pueden compartir identificador de fragmento original: son porciones distintas del mismo texto, no contenido duplicado.

Re-ordenamiento fino. La búsqueda gruesa puntúa fragmentos de aproximadamente 450 tokens, mientras que la evaluación de fragmentos se realiza sobre el texto de los sub-fragmentos entregados. Sin un nuevo cálculo de similitud, los sub-fragmentos heredan la posición de su fragmento padre y la mitad menos pertinente de un buen fragmento puede anteponerse a la mitad excelente del siguiente. Por ello, los sub-fragmentos procedentes de los 25 mejores candidatos se codifican con el mismo encoder del índice y se reordenan según su propia similitud con la consulta. La operación emplea exclusivamente vectores y el encoder ya presente, sin intervención de ningún modelo generativo.

La profundidad del conjunto re-ordenado se verificó empíricamente: en once de trece consultas analizadas, al menos uno de los diez fragmentos finales procede de un candidato situado más allá de la decimoquinta posición, y en dos casos procede exactamente de la vigésimo quinta. El re-ordenamiento aprovecha por tanto la profundidad completa del conjunto examinado.

6.4 Post-filtros

Deduplicación de fragmentos. El solapamiento de una oración entre fragmentos consecutivos hace que dos fragmentos vecinos compartan texto. Devolver ambos consumiría posiciones del resultado sin aportar información nueva y penalizaría la métrica. Se comparan mediante similitud de Jaccard sobre el conjunto de palabras con umbral de 0,8, y el fragmento descartado se sustituye por el siguiente candidato disponible. En la entrega final ninguna de las 50 consultas devuelve texto repetido.

Umbral mínimo de similitud: descartado. Eliminar fragmentos por debajo de una similitud mínima habría impedido garantizar exactamente diez fragmentos por consulta,

cantidad que la especificación exige y cuya violación se penaliza. Se prefiere entregar un décimo fragmento mediocre antes que nueve.

Filtrado por fenómeno: descartado. Las consultas no vienen etiquetadas con su fenómeno temático; cualquier asignación constituiría una inferencia propia. Se empleó como señal de diagnóstico para evaluar estrategias, nunca como filtro en el sistema entregado.

6.5 Limitaciones conocidas

Afinidad del encoder por el idioma de la consulta

Se identificó y cuantificó la principal limitación del sistema. Para las dieciséis consultas del primer fenómeno se midió la similitud máxima que alcanza cada fuente del corpus:

Fuente	Similitud media	Fragmentos	Idioma
CEEEP	0,861	83	Español
ILIA	0,844	2.208	Español
DAIO	0,834	1.957	Inglés
CSET Georgetown	0,831	3.909	Inglés
CENIA	0,823	276	Español
AI Index (Stanford)	0,815	20.405	Inglés
Atlantic Council	0,811	936	Inglés

La ordenación coincide casi exactamente con el idioma: las fuentes en español promedian 0,843 frente a 0,823 de las fuentes en inglés, una diferencia constante en las dieciséis consultas.

El dato que aísla la causa es que el AI Index dispone de diez veces más fragmentos que ILIA y alcanza una similitud inferior. Un mayor número de fragmentos supone más oportunidades de obtener una coincidencia alta; si aun así queda por debajo, la explicación no reside en el tamaño ni en la cobertura temática.

El comportamiento se confirmó de manera simétrica formulando la misma pregunta en ambos idiomas: la versión en inglés devuelve tres documentos en inglés y la versión en español, tres en español. No se trata por tanto de una preferencia por un idioma concreto, sino de afinidad por el idioma de la consulta.

La explicación es que los encoders multilingües proyectan todos los idiomas a un espacio común mediante una alineación imperfecta: parte de la capacidad del vector codifica el idioma del texto y no únicamente su significado. Probablemente se suma un efecto de registro, dado que las consultas comparten estilo con las fuentes en español más que con informes técnicos en inglés.

La consecuencia práctica es que el primer fenómeno, cuyo corpus es mayoritariamente anglófono, recibe documentos predominantemente en español. Afecta a dieciséis de las cincuenta consultas; los otros dos fenómenos no se ven comprometidos.

Las vías de corrección, por orden de eficacia, serían: incorporar un segundo encoder con mejor alineación entre idiomas —los entrenados sobre pares de traducción la logran considerablemente más estrecha— y fusionar ambos rankings; codificar la consulta también en inglés, alternativa inviable en este contexto porque la traducción exigiría un modelo generativo; o normalizar las puntuaciones por idioma antes de ordenar, opción económica pero imposible de calibrar sin datos de validación.

7 . Componente adicional: Grafo de conocimiento (§7)

Para extraer más contexto del corpus, construimos un grafo dirigido relacionando entidades extraídas de los textos (§7.2):

7. Reconocimiento de entidades (NER): Usamos el modelo Davlan/xlm-roberta-base-ner-hrl de HuggingFace. Es un modelo multilingüe compatible con la misma arquitectura de nuestro modelo principal (XLM-R).
8. Extracción de relaciones: Implementamos reglas lingüísticas básicas. Si dos entidades aparecen a menos de 200 caracteres de distancia (aprox. la misma oración), buscamos verbos clave entre ellas según el idioma (por ejemplo: raíces como desarroll- o develop-, regul-, etc.). Si no hay un verbo explícito, se marcan simplemente como se_relaciona_con.
9. Generación del grafo: Usamos networkx.MultiDiGraph. Cada nodo y relación guarda como atributo el origen exacto (doc_id y chunk_id) para asegurar la trazabilidad exigida. El resultado se exporta a grafo/grafos.graphml.

¿Cómo lo usamos en las búsquedas? (§8.5): Cuando entra una consulta, buscamos las entidades presentes usando el mismo modelo NER. Luego, buscamos esas entidades en el grafo y priorizamos los documentos de donde salieron esas conexiones. Finalmente, cruzamos el puntaje del grafo con el de FAISS usando Reciprocal Rank Fusion (RRF). RRF es excelente para esto porque combina posiciones en rankings en lugar de puntajes crudos, evitando problemas de escala.

Dimensiones del grafo en el corpus completo: [COMPLETAR: nº entidades, nº relaciones, % de aristas tipadas vs. genéricas].